当代人工智能：实验一报告

git链接：https://github.com/pck-altra/Contemporary-AI.git

分支：homework01

姓名：潘淳恺

学号：10245501437

时间：2026.9.17

一、实验目标

使用指定的数据集完成一个新闻十分类的典型机器学习分类任务。

使用多种分类算法与调参技巧对测试结果进行优化。

二、知识查询&概念理解

1. **TF-IDF**：用于将文本转化为向量表示。TF（词在文档内的频率）乘 IDF（log(语料大小 / 出现该词的文档数)），再 L2 归一化。一个较高的tf-idf值表示该词在该文档中出现次数多且在全局中出现次数较少。
2. **四种算法原理**：
   - **朴素贝叶斯**：贝叶斯定理 + 条件独立假设，秒级训练，传统文本 baseline
   - **SVM**：最大化分类间隔，文本分类上线性核几乎总是最优
   - **逻辑回归**：线性 + softmax + 交叉熵 + L2，输出概率、稳定、可解释
   - **MLP**：多层非线性网络，能学特征交互但训练慢、调参难

三、实验过程

1. 查看数据集

训练样本数共7368条，均为已标注，共划分为10个类别。

按照训练80%，验证20%进行划分。训练 5894 / 验证 1474，10 类每类约 147 个验证样本，统计意义足够。

2. 提取文本特征

调用TfidfVectorizer使用tfidf将文档内容转化为向量表示，并进行简单的数据清洗。

关键参数设置：

min_df=5,　　*# (2) <5 个文档出现的词丢掉*

max_df=0.95,　　*# (3) >95% 文档出现的词丢掉*

token_pattern=r"(?u)\b[A-Za-z][A-Za-z]+\b",　*# (8) 单字符/数字/标点直接丢*

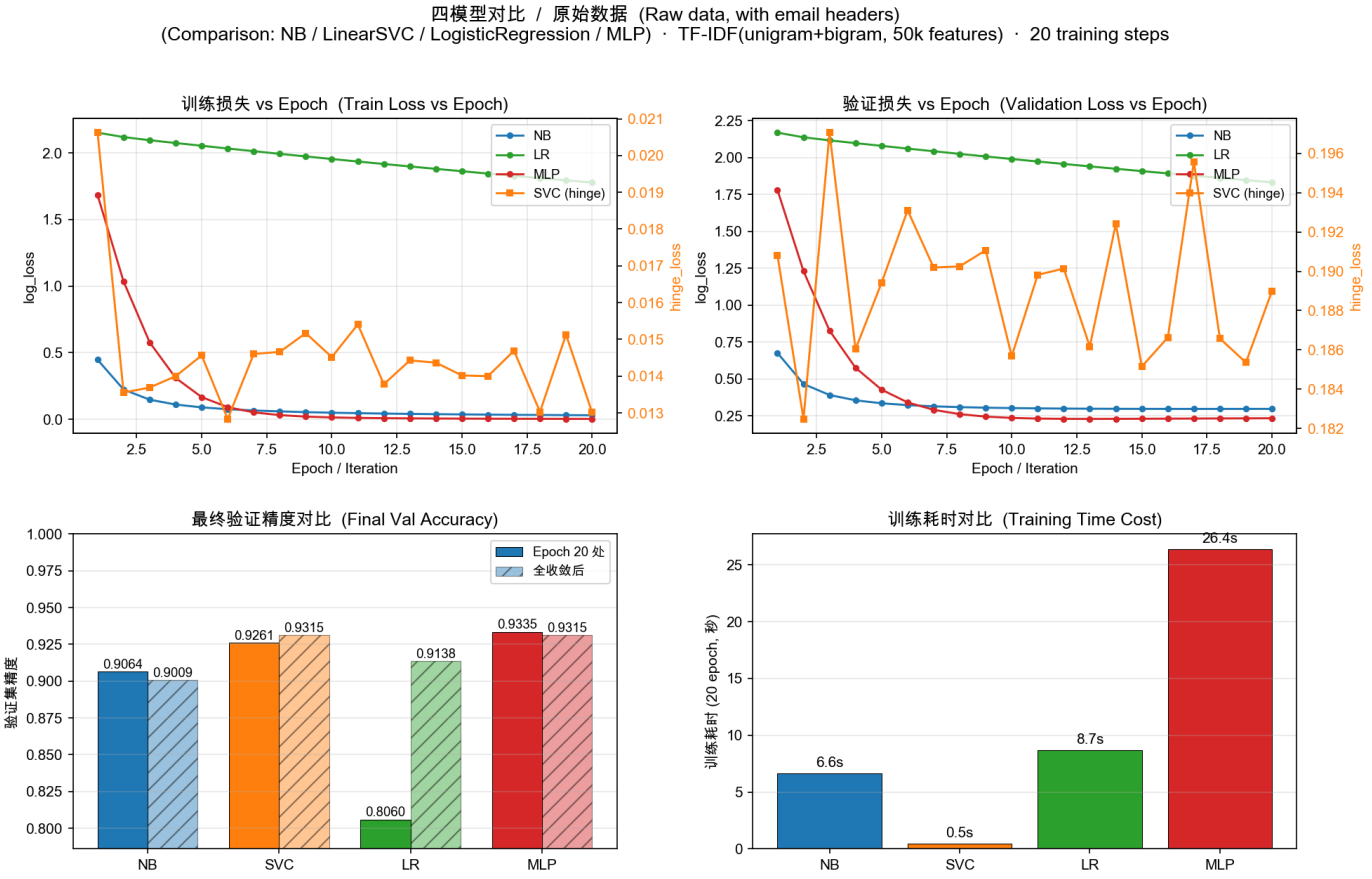
3. 训练过程

使用四种分类算法在相同数据集上进行训练

模型	关键超参数	训练策略
MultinomialNB	`alpha=1.0` (Laplace 平滑)	`partial_fit`，每 epoch 92 个 batch，打乱顺序
Linear SVM	`SGDClassifier(loss='hinge', penalty='l2', alpha=1e-4, eta0=0.01)`	`warm_start=True, max_iter=1`，逐 epoch 训练
LogisticRegression	`C=1.0, penalty='l2', solver='lbfgs'`	`warm_start=True, max_iter=1`，逐 lbfgs 迭代
MLP	`hidden_layer_sizes=(100,), activation='relu', solver='adam', alpha=1e-4, lr=1e-3, batch_size=200`	`warm_start=True, max_iter=1`，逐 epoch 训练

4. 训练结果

将四种算法统一跑20个epoch进行可视化对比



- NB作为baseline表现最差，且在图像中出现过拟合征兆，全收敛后验证精度为0.9009
- SVC第 1 步就基本收敛，后续在最小值附近震荡。训练速度快，收敛精度为0.9315
- LR 全收敛可达 0.9138，但 20 步远不够（必须给足迭代次数才能达到收敛）
- MLP 训练耗时是 SVC 的 51 倍，但精度持平，性价比最低。（推测原因：词表向量维度为50000，MLP需要进行两两组合，特征组合爆炸）

5. 优化尝试

当前最优情况：TF-IDF + LinearSVC

收敛后验证集精度：**0.9315**

训练耗时：0.4s

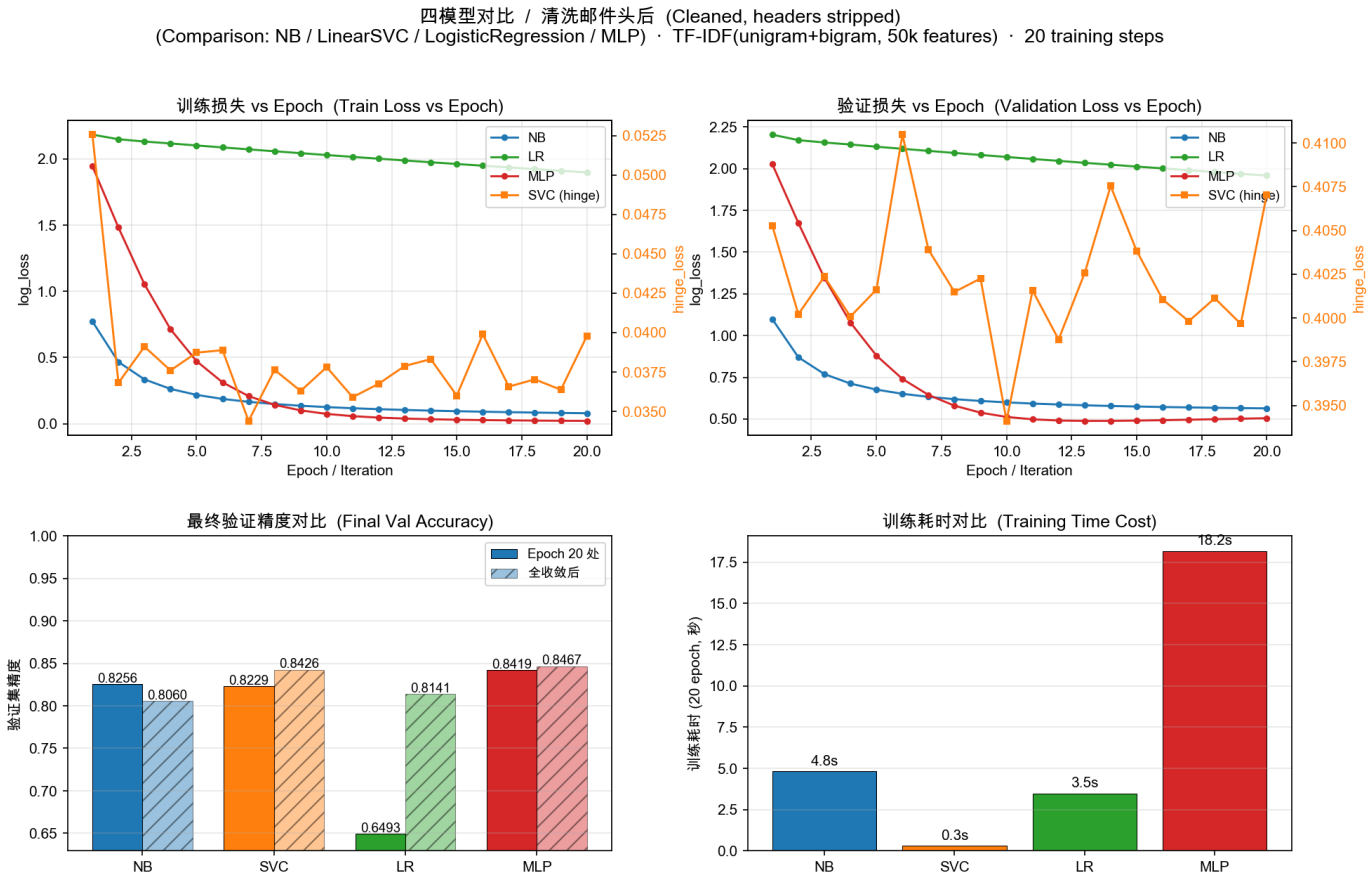
预测标签文件：predictions_svc_raw.csv

优化尝试1: 去除邮件头

想法：邮件头中含有收件人/寄件人等格式化信息会给训练过程提供噪声

操作：编写脚本去除邮件头部信息，只保留正文部分

优化结果：使用相同程序生成对比图表



- 结果发现是负优化，四种算法的收敛精度均出现了降低，最高为0.8467
- 推测：邮件头中包含邮件主题、所属组织（间接反映研究领域），属于直接且显著的分类特征，所以丢掉之后全四个算法下滑。

优化尝试2: BERT微调

想法：使用BERT预训练模型并使用训练集中的数据微调110M参数进行预测

操作：跑5个epoch，早停机制为2个epoch无提升

结果：训练耗时 28.7 min

```
=== BERT Fine-tuning Results ===
Training device: NVIDIA GeForce RTX 4060 Laptop GPU
MAX_LEN: 512
Epochs: 5 (Early stopping patience: 2)
Final val_acc: 0.9342
Epochs run: 5
Each epoch: 0.8752 0.9233 0.9220 0.9342 0.9322
Total training time: 28.7 minutes
Test predictions: 2457 rows
```

得到最佳验证精度为**0.9342**，超过了TF- IDF的0.9315

预测结果保存为**predictions_bert_raw.csv**

优化尝试3 : 投票融合

想法：BERT是异构模型，与其他传统分类算法存在较大差异，使用硬投票方式或许可以增加准确率

操作：拉取模型一致率矩阵

	BERT	MLP	SVC	NB	val_acc
BERT	—	0.9121	0.9190	0.8926	0.9342
MLP	0.9121	—	0.9711	0.9385	0.9108
SVC	0.9190	0.9711	—	0.9345	0.9315
NB	0.8926	0.9385	0.9345	—	0.9009

选取BERT+MLP+SVC 硬投票，统计投票情况

反对 BERT 的模型数	样本数	解读
MLP+SVC+NB 三票全反	161 条	三个独立模型同时都认为 BERT 错了，融合大概率比 BERT 单独更准
两票反对	213 条	部分被改，融合有理由跟随多数

将三票全反的情况修正为MLP+SVC+NB的预测结果，理论更优

预测保存为**predictions_fusion_bert_mlp_svc.csv**

6.思考与拓展

问题 1：为什么 SVM 和 LR 在这个数据集上表现好?

文本数据"高维 + 稀疏"的特性，恰好匹配线性模型的归纳偏置。

(1) 几何上的"自由度过剩"

在 d ≫ n 的空间里，任意一组样本几乎都线性可分——维度足够多，就能"摊开"任何一团点。线性模型在这片空间里足够用，不需要非线性也能划出清晰边界。

(2) 稀疏性带来的两个好处

- 多数特征为 0：50000 维里非零占比仅 ~0.46%，权重矩阵实际只被少量 token 激活 → 等价于隐式正则化
- 特征之间近似正交：稀疏向量内积趋近于 0，SVM 的"最大间隔"几何意义明确

问题 2：MLP 能否通过调结构/超参数进一步提升？是否过拟合?

当前配置

MLPClassifier(hidden_layer_sizes=(100,), max_iter=100,

alpha=1e-4, learning_rate_init=1e-3, batch_size=200)

- 第一层权重 = 50000 × 100 = 5,000,000 个参数
- 训练样本 5894 条，参数/样本比 ≈ 848

这个比例已经偏高，任何"加深/加宽/加 epoch"都会放大过拟合。

当前瓶颈在特征，不在模型

MLP 的本质是：

$\text{softmax}(W_2 \cdot \text{ReLU}(W_1 x + b_1) + b_2)$

- 第一层已经在做"降维"，把 50000 维压到 100 维；
- 100 个神经元能表达的非线性非常有限；
- 想要有0.5 pp 以上的提升，必须改特征或加大隐层（但代价是大量训练时间 + 显著过拟合风险）。

问题 3：除 TF-IDF 之外还有哪些文本表示方法?

离散词袋：把文档看作一个词的集合，忽略词序和语法结构，用词频或词的重要性来描述文档。

静态词向量：通过大量无标注文本预训练，把每个词映射为一个低维稠密向量，让语义相近的词在向量空间里位置相近，表示结果是低维稠密向量。代表Word2Vec

上下文相关：词的表示不再固定，而是根据当前句子的上下文动态生成，使用深度神经网络让同一个词在不同语境下拥有不同向量。代表BERT

稀疏-稠密混合与检索增强：结合稀疏表示的可解释性和稠密表示的语义能力，针对检索和大规模语义匹配场景做专门优化。